

Direcciones

Población: conjunto que representa todas las medidas de interés del investigador

- Muestra: subconjunto de medidas tomadas de la Población de interés
- Unidad experimental: el objeto a medir
- Muestra de unidades: M UE
- Población de unidades: todas las UE
- Muestra estadística: el valor de la variable característica de m UE
- Población estadística: el valor de la variable de todas las U.E

Obs: siempre es más importante la Población que la muestra porque la Población es el conjunto completo de todos los elementos que se quieren estudiar, mientras que la muestra es sólo una parte de la Población

Objetivo de la estadística → El objetivo es permitir inferencias. Si tomamos bien una muestra, podemos inferir sobre la Población

* El procedimiento de análisis puede ser:

1) Estadística descriptiva: utiliza métodos numéricos

1) **ESTADÍSTICA DESCRIPCIÓN**: Utiliza métodos numéricos y gráficos para resumir, o para representar la información, o para descubrir modelos en un conjunto de datos dado. (**ANÁLISIS EXPLORATORIO DE DATOS**)

2) **ESTADÍSTICA INFERENCIAL**: Utiliza los datos muestrales para hacer estimaciones o tomar decisiones o hacer proyecciones sobre un conjunto más grande de datos.

variables → siempre tengo que pensar en la naturaleza de la variable

X: "concentración de arsénico de un pozo de agua de HLC6, LP"

• Qualitativas

{ Nominal (ej: sexo, color ojos...)
Ordinal (ej: educación, calificación de una evaluación)
Puedo definir
en orden por ej: "alto, bajo, mucho, poco"


• Quantitativas

{ Discretas (ej: número de hijos)
Relacionadas ($\mathbb{N}_0 \cup \mathbb{Z}^+ \cup \mathbb{Z} \geq 0$)
2 en conteo
Continuas (ej: Altura, Peso, Temperatura)
IR

Son + importantes
en la estadística
experimental

Escala de medidas

QUALITATIVO
Nominal
Ordinal



* Distribución de Frecuencias Para Variables Qualitativas


↳ las variables de tipo Cuantitativo continuas

se pueden "categorizar" y transformarlas


en variables de tipo Qualitativo

Se representa:

- "gráfico de sectores"



• Diagrama de barras



← menos apropiado para variables qualitativas

* Distribución de Frecuencia para Variables Cuantitativas

↳ lo primero que hay que hacer es ordenar el conjunto de datos mediante el sistema de "Tallo y hojas" (no pierdo datos!)

clases o
intervalos

[100 - 200)	28	30	45
[200 - 300)	2	15	22
:			

* **Marcas de clase:** es el punto medio entre los valores de un intervalo.

Al utilizar la tabla de distribución de frecuencias se pierden datos.

Fórmula de Sturges

↳ una forma de determinar el número de

intervalos:

$$\# \text{intervalos} = 1 + 3,3 \cdot \log(n) \quad \begin{matrix} \text{Tamaño muestral} \\ \text{Por ej: los 30 botos de} \\ \text{esquí o equivalente} \end{matrix}$$

$$\bullet \# \text{intervalos} = 1 + 3,3 \cdot \ln(n)$$

OBS: un cálculo nos da el número mínimo de intervalos y otro el máximo de intervalos

Amplitud de los intervalos (se suele redondear)


$$\Delta_i = \frac{\text{rango}}{\text{intervalos}} = \frac{\text{máx rango} - \text{mín rango}}{\# \text{intervalos}}$$

Histograma → gráfico para variables cuantitativas

Continuas

Si los intervalos o clases tienen la misma amplitud se puede construir el histograma a partir de los pares (clases, n_i) o (clases, f_i)

Si los intervalos o clases tienen distinta amplitud hay que formar pares usando la densidad: $\frac{n_i}{\Delta_i}$ o $\frac{f_i}{\Delta_i}$ (clases, densidad)




* Distribución de Frecuencias para variables

cuantitativas discretas

↳ la tabla de Frecuencias es similar a la tabla de Frecuencias para variables cualitativas o cuantitativas continuas. La diferencia es que la variable, en este caso, toma valores enteros incluido el cero.


Se utiliza un gráfico de Bastones



usar gráfico de barras
no es apropiado. ↴

Si n = 10 - Dm 10 - Co - Simetría →





Medidas de Posición Central

Están diseñadas para brindar al investigador algunos valores cuantitativos respecto de sus datos, por ejemplo saber cuál es la ubicación central en su muestra.

* Mediana → es el valor medio de un conjunto de datos

Pasos: 1) ordenar los datos

$$2) \tilde{x} = \begin{cases} x\left(\frac{n+1}{2}\right) & \text{si } n \text{ es impar} \\ \frac{x\left(\frac{n}{2}\right) + x\left(\frac{n+1}{2}\right)}{2} & \text{si } n \text{ es par} \end{cases}$$

Cuando los datos están agrupados por clases o por intervalos, la mediana es el punto medio del intervalo que acumula el 50% de los datos.

* Media (media aritmética)

↳ Es la suma de todos los valores observados dividido por el número total de ellos

$$\bar{X} = \left(\sum_{i=1}^k x_i \right) \cdot \frac{1}{n}$$

↳ Variables cuantitativas discretas

$$\bar{X} = \frac{1}{n} \cdot \sum_{i=1}^k x_i \cdot n_x$$

↳ Variables cuantitativas continuas

$$\bar{X}' = \frac{1}{n} \cdot \sum_{i=1}^k \underline{x_i'} \cdot n_i$$

↓
marca de clase

OBS: al calcular la media utilizando la tabla (datos agrupados) obtenemos una media aproximada porque utilizamos la marca de clase que es un representante del intervalo.

* Moda → es el valor de la variable que se repite con mayor frecuencia en un conjunto de datos.

- Si todos los datos se repiten una sola vez entonces el conjunto no tiene moda

- Si hay dos valores que se repiten igual

Cantidad de veces, la moda es **Bimodal**.

- Sólo se puede usar para variables cualitativas
- Para calcular la moda conviene ordenar los datos y ver cuál se repite más veces
- Si miramos en una tabla de distribución de frecuencias, agrupado por intervalos, se habla de clase modal, y un valor estimativo es el punto medio de esa clase modal.

Desviós → mide cuánto varían los datos del valor de la media

En cualquier conjunto de datos, la suma de los desviós siempre es cero, por lo tanto NO ES UNA BUENA MEDIDA DE DISPERSIÓN

$$\sum_{i=1}^n (x_i - \bar{x}) = 0.$$

• Desvió medio: $\frac{1}{n} \cdot \sum_{i=1}^n |x_i - \bar{x}|$

• Desvió: $x_i - \bar{x}$

Variancia → Es una medida que expresa un desvió cuadrático medio y suele causar algunos problemas de interpretación

Por eso se calcula el desvió estandar:

$$DEVIÓ ESTANDAR = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

↳ Por eso se tiene ..

$$D.E(x) = \hat{\sigma}_x = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^2}$$

OBS. El desvío estándar está expresado en la misma unidad de medida que los valores del conjunto de datos.

Es una medida de dispersión o variabilidad que acompaña a la media aritmética.

$$\hat{\sigma}_x = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n (x_i - \bar{x})^2} \rightarrow \text{conjunto } \underline{\text{no agrupado}}$$

$$\tilde{\hat{\sigma}}_x = \sqrt{\frac{1}{n} \cdot \sum_{i=1}^n [(m_i - \bar{x})^2 \cdot n_i]} \rightarrow \text{conjunto agrupado}$$

↓
marca de clase

Es un desvío estándar aproximado pq se utiliza la marca de clase en vez de

Coeficiente de

$$\text{variación} \rightarrow Cv(x) = \frac{s}{\bar{x}} \begin{matrix} \rightarrow \text{desvío} \\ \rightarrow \text{media} \end{matrix}$$

OBS: Si los datos muestran una distribución simétrica la media " \bar{x} " es una buena medida de posición central, y por lo tanto, el desvío estándar $\hat{\sigma}_x$ es una buena medida de dispersión.

Regla empírica → Si una variable tiene un

comportamiento aproximadamente simétrico, entonces verifica la regla empírica.

$$(s = \tilde{\sigma})$$

$$\bullet \bar{x} \pm 1.s = (\bar{x} - s, \bar{x} + s) : \approx 68\%$$

• $x \pm 1.s$ respecto

deberían caer
aprox. 68% de los
datos

• $\bar{x} \pm 1.S = (\bar{x} - S, \bar{x} + S) \approx 68\%$ DATOS

" x ± un desvió respecto
de la media"

• $\bar{x} \pm 2.S = (\bar{x} - 2.S, \bar{x} + 2.S) \approx 95\%$

• $\bar{x} \pm 3.S = (\bar{x} - 3.S, \bar{x} + 3.S) \approx 99\%$

MAD → cuando los datos presentan una distribución Asimétrica, la mejor medida de posición central es la mediana. Por lo tanto MAD es la mejor medida de dispersión

$MAD = M_d(|x_i - M_d(x)|)$

PASOS:

- 1) Calcular los desvíos $x_i - M_d(x)$
- 2) Calcular los valores absolutos $|x_i - M_d(x)|$
- 3) Ordenar los valores absolutos de los desvíos
- 4) Hallar la mediana de este nuevo conjunto = **MAD**.

Medidas de Asimetría

* La distribución está sesgada a derecha



(tiene sesgo positivo o
asimetría positiva)

* La distribución está sesgada a izquierda

(sesgo negativo o asimetría)

• $M_3 = \frac{\sum_{i=1}^n (x_i - \bar{x})^3}{n}$

$M_3 = 0 \Rightarrow$ la distribución es



Coeficiente de variación

$$\hookrightarrow CV \% = \frac{s}{\bar{x}} \times 100 \quad \text{con } \bar{x} > 0.$$

Boxplot → es un gráfico que sirve para visualizar el comportamiento de los datos de una muestra. Se construye con 5 medidas de posición:

* $\min(x)$ = mínimo valor del conj. de datos

* $q_1 = 1^{\circ}$ cuartil, es la mediana de los valores que caen por debajo de la mediana. (25% de los datos)

* $q_2 = M_d$ 2º cuartil, es la mediana (50% de los datos)

* $q_3 = 3^{\circ}$ cuartil, es la mediana de los valores que caen por encima de la mediana (75% de los datos)

* $\max(x)$ = máximo valor del conj. de datos.

* $\max(x)$ = máximo valor del conj. de DATOS.

El gráfico suele hacerse de manera horizontal, al menos de que se quiera comparar con otro gráfico y se hace en vertical.

ED:

